

UNIVERSIDAD  
COMPLUTENSE  
DE MADRID



Autor: María José  
Gómez Silva

# Machine Learning con Python. Semana 1.

## CAPÍTULO 1. INTRODUCCIÓN AL MACHINE LEARNING.

### 1.3 Tipos de Aprendizajes y tipos de Modelos

#### TIPOS DE APRENDIZAJE

El proceso de aprendizaje en una máquina es iterativo, es decir, consiste en la repetición de ciclos, y depende de los datos de ejemplo de los que se disponga. Mediante la observación iterativa de múltiples ejemplos la máquina o programa, en cada ciclo, adquiere experiencia en la realización de una tarea, y trata de aprender de sus errores para corregir su modo de realizar la tarea y así mejorar su rendimiento en el ciclo siguiente.

El proceso de aprendizaje a menudo es llamado *entrenamiento*, debido a la naturaleza iterativa del proceso, en el que la mejora es progresiva, y la experiencia es adquirida con numerosos “intentos” de realización de la tarea.

Dependiendo de la tarea a resolver y de los datos disponibles para abordarla, se puede elegir entre diferentes tipos de aprendizaje. Estos son: aprendizaje supervisado, aprendizaje no supervisado, y aprendizaje por refuerzo.

#### Aprendizaje Supervisado


El aprendizaje supervisado es aquel en el que el proceso de mejora del rendimiento es guiado por la comparación de la predicción que ofrece el modelo con respecto a la solución o salida real que se espera obtener.

Para realizar este tipo de entrenamiento es necesario disponer de ejemplos tanto de datos de entradas como de sus correspondientes salidas. En otras palabras, se necesitan ejemplos para los cuales ya conozcamos el resultado o salida real. Esa salida o solución conocida, que sirve como referencia, recibe diversos nombres en la literatura. Algunos de ellos son: *etiqueta*, *anotación*, o *ground truth*, y a la labor de registrarlas, se le denomina etiquetado o anotación de los datos.

Por ejemplo, si queremos entrenar, con un aprendizaje supervisado, un modelo que determine si en una fotografía aparece el cielo o no, necesitaremos múltiples fotografías de ejemplo (unas con cielo y otras sin él) y además las etiquetas correspondientes, es decir, debemos pasarle al algoritmo de aprendizaje la solución para cada imagen, o lo que es lo mismo la información de si tiene cielo o no. En el ejemplo anterior del empresario que anunciaba su producto en la radio, los minutos de publicidad eran los datos de entrada, y para cada ejemplo de entrada, su etiqueta asociada era el volumen de ventas correspondiente.

Lo que finalmente se espera del modelo es que ofrezca predicciones similares a las etiquetas tomadas como referencia.

En conclusión, el aprendizaje supervisado necesita conjuntos de datos etiquetados, es decir, le tenemos que decir al modelo qué es lo que queremos que aprenda, como se muestra en la Figura 1.



*Figura 1. Esquema de aprendizaje supervisado*

Dependiendo del tipo de etiqueta, dentro del aprendizaje supervisado existen dos tipos de modelos: los de regresión, donde la etiqueta es una variable continua y los de clasificación, donde la etiqueta es discreta. Ambos modelos serán explicados con mayor detalle en la siguiente sección.

## **Aprendizaje No Supervisado**

A diferencia del aprendizaje supervisado, en el no supervisado no se sigue una referencia de la que aprender. El aprendizaje no supervisado emplea datos que no han sido etiquetados ya que no trata de predecir un determinado valor a la salida. Este tipo de entrenamiento se emplea para resolver tareas consistentes en el análisis de los datos para estructurarlos o agruparlos por afinidad, como se indica en la Figura 2.

Este tipo de aprendizaje no se emplea para predecir una salida a partir de los datos de entrada. No predice una solución, ni clasifica los datos de entrada con una etiqueta, sino que extrae nuevo conocimiento a cerca de los datos de entrada, los organiza, agrupa, o incluso simplifica, extrayendo la información fundamental de los mismos.

Algunos ejemplos de modelos que emplean aprendizaje no supervisado son los de agrupación (clustering), los de detección de anomalías, los asociativos y los de reducción de la dimensionalidad. Que serán definidos en la siguiente sección.




Figura 2. Esquema de Aprendizaje No Supervisado

## Aprendizaje por Refuerzo

El aprendizaje por refuerzo se basa en recompensar los comportamientos deseados y penalizar los no deseados. Este aprendizaje se basa en la existencia de un *agente* (maquina o programa) que realiza acciones o toma decisiones, y un *ambiente* o entorno al que afectan las acciones y decisiones del agente, como se representa en la Figura 3. Según el efecto de las acciones del agente en el entorno, éstas serán recompensadas o penalizadas. El agente debe disponer de mecanismos para percibir e interpretar el entorno, y mediante la ejecución de acciones aprenderá a través de prueba y error.

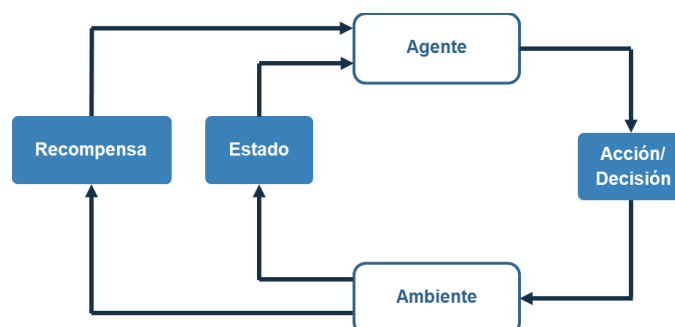


Figura 3. Esquema de Aprendizaje por Refuerzo.

En lugar de emplear etiquetas de referencia para guiar el aprendizaje, este método fija objetivos a lograr, y asigna recompensas y penalizaciones a determinadas acciones. Concretamente se asignan valores positivos a las acciones deseadas para animar al agente a realizarlas y valores negativos a los comportamientos no deseados. Con el tiempo, el agente aprende a evitar lo negativo y buscar lo positivo.

Este tipo de aprendizaje lleva al agente a buscar recompensas globales a largo plazo para alcanzar una solución óptima. Los objetivos a largo plazo ayudan al agente a no

estancarse en objetivos menores. Si el agente únicamente valorase la recompensa a corto plazo podría quedarse estancado repitiendo la última acción con la que recibió una buena recompensa. Por ello, se debe lograr un equilibrio entre *explorar* lo desconocido y *explotar* los recursos en el ambiente. Eso es conocido como el dilema de exploración/explotación.

En el aprendizaje por refuerzo no se requieren etiquetas para los datos, por lo tanto, no es de tipo supervisado. Sin embargo, tampoco es de tipo no supervisado, ya que en el aprendizaje por refuerzo se persigue un objetivo a partir de los datos, y no la estructuración o agrupación de los mismos. Este método de aprendizaje puede entenderse como una forma de dirigir el aprendizaje automático no supervisado hacia un objetivo mediante recompensas y penalizaciones, y sin necesidad de etiquetar explícitamente los datos.

El aprendizaje por refuerzo se emplea en áreas como la robótica, la optimización y el control de sistemas. Destaca su aplicación en el ámbito del desarrollo de videojuegos. Por ejemplo, Pacman es un juego basado en aprendizaje por refuerzo. El agente recibe información sobre las reglas del juego y aprende a jugar por sí mismo. Al principio, se comporta de manera aleatoria, pero a medida que aprende realiza movimientos más sofisticados.

Uno de los métodos de aprendizaje por refuerzo más conocido y empleado es el *Q-learning*, que trata de aprender un conjunto de reglas o normas de comportamiento llamada política. Recibe su nombre, por la inicial Q de la función de calidad, “quality” en inglés, ya que esta función devuelve la recompensa y representa la “calidad” de la acción tomada.

## TIPOS DE MODELOS O TAREAS EN MACHINE LEARNING

### Regresión

Los modelos de regresión crean un mapa entre las variables de entrada y una función continua, por lo tanto, permiten predecir una salida que toma valores reales continuos. Los modelos de regresión se entrenan mediante aprendizaje supervisado.

Un tipo de regresión ampliamente empleado es la regresión lineal, donde la función que relaciona la salida con la o las entradas es lineal. En el caso concreto de tener una única variable de entrada, la ecuación que define la salida del modelo en función de la entrada sería la de una línea recta, como se observa en la Figura 4.

Un ejemplo de problema de regresión sería el de predecir el precio de venta de una vivienda en función de su tamaño, a partir de datos de ventas previas.




Figura 4. Modelo de regresión lineal.

## Clasificación

Los modelos de clasificación mapean las variables de entrada en categorías discretas (también llamadas clases), es decir, clasifican una determinada muestra a partir de las variables de entrada tomadas. Estos modelos predicen una salida que toma valores discretos. Estos valores discretos son las etiquetas correspondientes a cada una de las clases posibles. Los modelos de clasificación se entrenan con aprendizaje supervisado.

Si el número de clases posibles es sólo de dos, hablamos de un modelo de clasificación binaria, como el que se muestra en la Figura 5. Si el número de clases es mayor que dos, se trata de una clasificación multiclase.





Figura 5. Modelo de clasificación binaria.

El ejemplo anterior de predicción del precio de una vivienda se puede transformar en un problema de clasificación haciendo que la salida del modelo sea si la vivienda se vende por más o menos del precio pedido. Se trata de una clasificación de las casas en dos categorías discretas basada en el precio.

## Clustering

El clustering es la agrupación de los datos basada en las relaciones entre las variables de entrada que se toman de los datos, véase la Figura 6. Estos modelos no atienden a ningún tipo de etiqueta o referencia, por lo que se trata de métodos de aprendizaje no supervisado.




*Figura 6. Modelo de clustering*

Un ejemplo de problema de clustering sería el caso en el que tenemos una colección de 2000 encuestas sobre la economía de una región y se busca una manera de agrupar las encuestas automáticamente en un número pequeño de grupos de encuestas similares, relacionadas por diferentes variables como la frecuencia de algunas palabras o longitud de los párrafos.

### **Detección de Anomalías**

Los detectores de anomalías se basan en la asunción de que la mayoría de los datos tomados tienen un comportamiento o valores normales. Los modelos de detección de anomalías no requieren de etiquetas de los datos, ya que modelan la distribución de probabilidad de todos los datos de entrada.

Si llegan datos, que, de acuerdo con el modelo, presentan poca probabilidad, estas muestras serán considerados como anómalas, como la muestra amarilla de la Figura 7.




*Figura 7. Modelo de detección de anomalías*

Un ejemplo de problema de detección de anomalías sería el caso en el que se identifica un producto defectuoso por los valores anómalos de algunas de sus características, que difieren mucho del resto (la mayoría) de productos en buenas condiciones.

## Aprendizaje Asociativo

Los modelos asociativos, como su nombre indica, asocian una nueva muestra con otras previamente estudiadas por similitud (similar al clustering), y además si las muestras previas fueron etiquetadas con anterioridad (han sido clasificadas), esa etiqueta también es asociada a la nueva muestra. Puede entenderse como una combinación de clustering y clasificación. En la Figura 8 se observa como una nueva muestra en azul claro ha sido asociada con una muestra anterior etiquetada como grupo verde.

Por ejemplo, un caso de aprendizaje asociativo sería el realizado por un doctor que a lo largo de años de experiencia forma asociaciones entre características de pacientes y diagnósticos de enfermedades confirmados. Si un nuevo paciente aparece, se basa en sus características para asociar una posible enfermedad, de acuerdo con la similitud con los pacientes previos. Difiere de un problema de clasificación, donde se buscaría una función que directamente relacionase las características del paciente con distintas enfermedades.



*Figura 8. Modelo de aprendizaje asociativo.*

## Reducción de dimensionalidad

Los métodos de reducción de dimensionalidad seleccionan o combinan las variables tomadas de los datos para reducir el número de las mismas, véase la Figura 9. La reducción de dimensionalidad suele ser un paso previo al entrenamiento de otros modelos. Las razones para tratar de disminuir la dimensionalidad de los datos de entrada son múltiples: reducir el tiempo de entrenamiento de los algoritmos, mejorar el rendimiento del modelo o facilitar la representación visual de los datos.

Los algoritmos de reducción de dimensionalidad emplean métodos estadísticos y matemáticos para transformar la base de datos original en una nueva con menos dimensiones. El inconveniente es que en el proceso se pierde algo de información. Sin embargo, para minimizar la relevancia de la información perdida, estos métodos realizan un análisis de componentes, es decir, un análisis de las variables de entrada disponibles. A partir de ese análisis seleccionan solamente las variables principales o más características, como el método PCA (Principal Component Analysis).






Figura 9. Reducción de la dimensionalidad de los datos

## Resumen de tipos de Aprendizaje

La Tabla 1 resume los tipos de aprendizaje y de modelos de Machine Learning definidos en las secciones previas:

Tabla 1. Tipos de aprendizajes y tipos de modelos en Machine Learning

Tipos de Aprendizaje	Tipos de modelos o tareas	Ejemplos de métodos.
<b>Supervisado</b>	Regresión	<i>Logistic regresion</i>
	Clasificación	<i>SVM, decision tree</i>
<b>No Supervisado</b>	Clustering	<i>k-means, hierarchical clustering</i>
	Detección de anomalías	
	Aprendizaje Asociativo	
	Reducción de dimensionalidad	<i>PCA</i>
<b>Por Refuerzo</b>		<i>Q-learning</i>

Dependiendo de las características del conjunto de datos del que disponemos se debe seleccionar el tipo de aprendizaje y de modelo que mejor se ajuste a las necesidades del objetivo perseguido.

## REFERENCIAS

<https://docs.python.org/3/tutorial/index.html>

<https://www.anaconda.com/products/individual>

<https://docs.jupyter.org/en/latest/>

<https://numpy.org/doc/stable/>

<https://pandas.pydata.org/docs>

<https://matplotlib.org/stable/index.html>

*Machine learning con Python y Scikit-learn* by Joaquín Amat Rodrigo, available under a Attribution 4.0 International (CC BY 4.0) at [https://www.cienciadedatos.net/documentos/py06\\_machine\\_learning\\_python\\_scikitlearn.html](https://www.cienciadedatos.net/documentos/py06_machine_learning_python_scikitlearn.html)

<https://www.drivendata.org/>